

Libro de Códigos (Code Book)

Proyecto 1 - Obtención y Limpieza de Datos - Data Science

Metadatos del Conjunto de Datos Limpio

- **Fecha de extracción:** 19 de julio de 2026 (*Fecha correspondiente a la corrida del script de descarga*)
 - **Fuente de los datos:** Portal web del Ministerio de Educación de Guatemala (MINEDUC) - Búsqueda de Establecimientos (http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/).
 - **Versión del conjunto limpio:** 1.0 (Julio 2026)
-

Diccionario de Variables

1. CODIGO

- **Descripción:** Identificador único del establecimiento educativo asignado por el MINEDUC.
- **Tipo de dato:** Alfanumérico (Texto).
- **Dominio permitido:** Cadena de caracteres que cumpla estrictamente con el patrón `##-##-####-##` (dígitos y guiones).
- **Valores posibles:** Múltiples códigos únicos, ej. `16-01-0137-46`.
- **Tratamiento aplicado:** Se verificó el patrón regex en el 100% de los registros. Se conservó como texto para no perder ceros a la izquierda y guiones. Normalización de espacios.
- **Variables derivadas:** Ninguna.

2. DISTRITO

- **Descripción:** Código del distrito escolar al que pertenece el establecimiento.
- **Tipo de dato:** Alfanumérico (Texto).
- **Dominio permitido:** Patrones `##-##-####` (detallado) o `##-###` (corto).
- **Valores posibles:** Ej. `16-006`, `01-01-0001`, `NA` (si no existe dato).
- **Tratamiento aplicado:** Normalización de espacios. Los valores truncados o vacíos evidentes (ej. `01-` sin el código completo) se asignaron a `NA`.
- **Variables derivadas:**
 - `DISTRITO_FORMATO` : (Categórico) Indica si el formato es 'detallado', 'corto', 'incompleto', 'vacío' o 'formato_no_reconocido'.
 - `DISTRITO_VALIDO` : (Booleano) `True` si cumple formatos aceptados, `False` en incompletos o vacíos.

3. DEPARTAMENTO

- **Descripción:** Nombre del departamento político-administrativo donde se ubica el centro educativo.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Los 22 departamentos oficiales de la República de Guatemala, más la partición "CIUDAD CAPITAL".
- **Valores posibles:** ALTA VERAPAZ, BAJA VERAPAZ, CIUDAD CAPITAL, GUATEMALA, PETÉN, QUICHÉ, SACATEPÉQUEZ, SOLOLÁ, etc.
- **Tratamiento aplicado:** Se convirtieron los textos a mayúsculas, se limpiaron espacios y se corrigieron tildes faltantes usando un catálogo estándar de departamentos (Ej. PETEN -> PETÉN).
- **Variables derivadas:** Ninguna.

4. MUNICIPIO

- **Descripción:** Nombre del municipio donde se ubica el establecimiento. En el caso de "CIUDAD CAPITAL", reporta la zona.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Catálogo oficial del INE/Wikipedia por departamento, y de ZONA 1 a ZONA 25 para Ciudad Capital.
- **Valores posibles:** COBÁN, MIXCO, ZONA 10, etc.
- **Tratamiento aplicado:** Transformación a mayúsculas, normalización de espacios y corrección de tildes según diccionario municipal.
- **Variables derivadas:**
 - MUNICIPIO_VALIDO : (Booleano) True si el municipio hace match exacto con el diccionario oficial del INE/Wikipedia para su departamento correspondiente, False de lo contrario.

5. ESTABLECIMIENTO

- **Descripción:** Nombre oficial del centro educativo.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Nombres en mayúsculas, letras, números y signos de puntuación válidos.
- **Valores posibles:** Múltiples (ej. INSTITUTO MIXTO NOCTURNO FRANCISCO MARROQUIN).
- **Tratamiento aplicado:** Eliminación de caracteres invisibles, normalización de múltiples espacios internos y reemplazo de acentos graves por agudos. Se eliminaron comillas dobles si envolvían toda la cadena. Valores vacíos explícitos se pasaron a NA . Unificación por similitud estricta (tildes).
- **Variables derivadas:** Ninguna.

6. DIRECCION

- **Descripción:** Dirección física de las instalaciones del establecimiento.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Direcciones (alfanumérico). NA si es placeholder.
- **Valores posibles:** Múltiples (ej. "6A. AVENIDA 1-15 ZONA 4").
- **Tratamiento aplicado:** Eliminación de espacios invisibles/múltiples, eliminación de signos de puntuación irregulares en los bordes. Reemplazo de placeholders ("SIN DATO", "---", etc.) por NA .
- **Variables derivadas:** Ninguna.

7. TELEFONO

- **Descripción:** Números de teléfono de contacto del establecimiento.
- **Tipo de dato:** Texto (lista de números separados por punto y coma ;).
- **Dominio permitido:** Dígitos de 8 caracteres separados por ; . NA si es faltante/inválido.
- **Valores posibles:** Ej. 22202870 , 22202870; 22202873 .
- **Tratamiento aplicado:** Se estandarizaron separadores (comas, "Y", "/"). Se reconstruyeron números abreviados (ej. 22202870-73 a 22202870; 22202873). Se eliminaron etiquetas como "FAX" y "EXT". Los caracteres imposibles se documentaron en observación.
- **Variables derivadas:**
 - TELEFONO_ORIGINAL : (Texto) El valor crudo para trazabilidad y auditoría.
 - TELEFONO_CANTIDAD : (Numérico entero) Cantidad de números extraídos exitosamente.
 - TELEFONO_VALIDO : (Booleano) True si todos los números extraídos tienen longitud válida (8 dígitos).
 - TELEFONO_OBSERVACION : (Texto libre) Motivos de invalidez o notas de extracción (ej. "incluye FAX", "vacío", "longitud inválida").

8. SUPERVISOR

- **Descripción:** Nombre de la persona encargada de la supervisión escolar del MINEDUC asignada.

- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Cadenas de nombres propios, NA si falta.
- **Valores posibles:** Múltiples (ej. JORGE EDUARDO PAQUE LAZARO).
- **Tratamiento aplicado:** Eliminación de múltiples espacios y caracteres invisibles. Corrección de acentos graves. Reemplazo de placeholders ("---", "S/D") a NA. Unificación automática de nombres idénticos que solo diferían por tildes.
- **Variables derivadas:** Ninguna.

9. DIRECTOR

- **Descripción:** Nombre del director del centro educativo.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Cadenas de nombres propios, NA si falta.
- **Valores posibles:** Múltiples nombres de personas.
- **Tratamiento aplicado:** Normalización completa (espacios, caracteres invisibles, corrección de acentos graves). Conversión de valores vacíos y placeholders genéricos ("---", "SIN DATO", ".") a valor nulo explícito NA. Unificación por presencia de tildes.
- **Variables derivadas:** Ninguna.

10. NIVEL

- **Descripción:** Nivel educativo de los datos extraídos (condición del proyecto).
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** "DIVERSIFICADO"
- **Valores posibles:** DIVERSIFICADO
- **Tratamiento aplicado:** Normalización de espacios y mayúsculas para estandarización.
- **Variables derivadas:** Ninguna.

11. SECTOR

- **Descripción:** Naturaleza jurídica / administración financiera del establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Lista controlada según sistema (ej. PRIVADO, OFICIAL, COOPERATIVA).
- **Valores posibles:** PRIVADO, OFICIAL, MUNICIPAL, COOPERATIVA.
- **Tratamiento aplicado:** Normalización de espacios y conversión a mayúsculas.
- **Variables derivadas:** Ninguna.

12. AREA

- **Descripción:** Tipo de área demográfica de asentamiento de la escuela.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** URBANA, RURAL (y SIN ESPECIFICAR por consistencia de origen).
- **Valores posibles:** URBANA, RURAL, SIN ESPECIFICAR.
- **Tratamiento aplicado:** Normalización de espacios y mayúsculas.
- **Variables derivadas:** Ninguna.

13. STATUS

- **Descripción:** Situación operativa actual del establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Estados operacionales del MINEDUC.
- **Valores posibles:** ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE.
- **Tratamiento aplicado:** Limpieza de espacios y estandarización a mayúsculas.
- **Variables derivadas:** Ninguna.

14. MODALIDAD

- **Descripción:** Idioma y enfoque educativo.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Modalidades lingüísticas reconocidas.
- **Valores posibles:** MONOLINGUE, BILINGUE.
- **Tratamiento aplicado:** Normalización de espacios, estandarización a mayúsculas.
- **Variables derivadas:** Ninguna.

15. JORNADA

- **Descripción:** Horario de funcionamiento de clases.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Jornadas del MINEDUC.
- **Valores posibles:** MATUTINA, VESPERTINA, NOCTURNA, DOBLE, INTERMEDIA.
- **Tratamiento aplicado:** Estandarización a mayúsculas, recortes de espacio.
- **Variables derivadas:** Ninguna.

16. PLAN

- **Descripción:** Plan o tipo de asistencia escolar.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Planes educativos del MINEDUC.
- **Valores posibles:** DIARIO(REGULAR), FIN DE SEMANA, SEMIPRESENCIAL, A DISTANCIA.
- **Tratamiento aplicado:** Remoción de espacios extra y conversión a formato uniforme.
- **Variables derivadas:** Ninguna.

17. DEPARTAMENTAL

- **Descripción:** Entidad Departamental del MINEDUC encargada de la administración sobre el establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Departamentos, con subdivisiones de GUATEMALA y QUICHÉ (Norte, Sur, Oriente, Occidente).
- **Valores posibles:** ALTA VERAPAZ, GUATEMALA NORTE, QUICHÉ NORTE, etc.
- **Tratamiento aplicado:** Conversión a mayúsculas, adición de tildes oficiales en concordancia con DEPARTAMENTO (Ej. QUICHÉ). Validado respecto al departamento base para asegurar congruencia jerárquica territorial.
- **Variables derivadas:** Ninguna.

Informe de Calidad de Datos (Antes vs. Después)

A continuación, se presenta la validación del conjunto de datos limpio comparando el estado inicial contra el final tras aplicar el proceso de normalización:

Métrica	Antes	Después	Justificación de cambios
Registros	11,867	11,867	No se eliminaron registros, el sistema de MINEDUC asocia un registro distinto por combinación jornada/plan.
Variables (columnas)	17	24	Se agregaron 7 columnas derivadas para validación explícita (DISTRITO_FORMATO, DISTRITO_VALIDO, MUNICIPIO_VALIDO, TELEFONO_ORIGINAL, TELEFONO_CANTIDAD, TELEFONO_VALIDO, TELEFONO_OBSERVACION).

Valores faltantes	4,263	4,286	Subida esperada. Placeholders tipo "---", "SIN DATOS" o "S/D" fueron convertidos a nulos explícitos (NA) para mediciones reales.
% de faltantes	2.11%	2.12%	Aumento derivado de la conversión de texto genérico a NA.
Variables con NA	6	6	Las variables que contienen datos nulos se mantuvieron estables (Director, Supervisor, Dirección, etc).
Duplicados exactos (fila completa)	0	0	No existían filas 100% idénticas en todas sus columnas en el origen.
Posibles duplicados parciales	3,726	2,075	Se redujeron drásticamente las discrepancias parciales (similitud difusa) gracias a la corrección estandarizada de tildes en nombres propios.
Establecimientos únicos	6,313	5,833	Al corregir variaciones ortográficas (ej. GONZÁLEZ vs GONZALEZ), entidades lógicamente idénticas se unificaron, reduciendo el total.

Nota: Todas las transformaciones aplicadas fueron guardadas para reproducibilidad en Reportes/RegistroTransformaciones.csv . Los duplicados parciales restantes se exportaron a Reportes/PosiblesDuplicadosParciales.csv para revisión manual del analista, de acuerdo con las instrucciones del proyecto que prohíben su eliminación automática.