

Code Book

Proyecto 1 - Obtención y Limpieza de Datos - Data Science

Integrantes

Nombre	Carne
Javier España	23361
Ángel Esquit	23221
Roberto Barreda	23354

Julio 2026

Metadatos del Conjunto de Datos Limpio

- **Fecha de extracción:** 19 de julio de 2026 (*Fecha correspondiente a la corrida del script de descarga*)
- **Fuente de los datos:** Portal web del Ministerio de Educación de Guatemala (MINEDUC) - Búsqueda de Establecimientos (http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/).
- **Versión del conjunto limpio:** 1.0 (Julio 2026)

Diccionario de Variables

1. CODIGO

- **Descripción:** Identificador único del establecimiento educativo asignado por el MINEDUC.
- **Tipo de dato:** Alfanumérico (Texto).
- **Dominio permitido:** Cadena de caracteres que cumpla estrictamente con el patrón ##-##-####-## (dígitos y guiones).
- **Valores posibles:** Múltiples códigos únicos, ej. 16-01-0137-46.
- **Tratamiento aplicado:** Se verificó el patrón regex en el 100% de los registros. Se conservó como texto para no perder ceros a la izquierda y guiones. Normalización de espacios.
- **Variables derivadas:** Ninguna.

2. DISTRITO

- **Descripción:** Código del distrito escolar al que pertenece el establecimiento.
- **Tipo de dato:** Alfanumérico (Texto).
- **Dominio permitido:** Patrones ##-##-#### (detallado) o ##-### (corto).
- **Valores posibles:** Ej. 16-006, 01-01-0001, NA (si no existe dato).
- **Tratamiento aplicado:** Normalización de espacios. Los valores truncados o vacíos evidentes (ej. 01- sin el código completo) se asignaron a NA.
- **Variables derivadas:**
 - **DISTRITO_FORMATO:** (Categórico) Indica si el formato es 'detallado', 'corto', 'incompleto', 'vacío' o 'formato_no_reconocido'.
 - **DISTRITO_VALIDO:** (Booleano) True si cumple formatos aceptados, False en incompletos o vacíos.

3. DEPARTAMENTO

- **Descripción:** Nombre del departamento político-administrativo donde se ubica el centro educativo.

- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Los 22 departamentos oficiales de la República de Guatemala, más la partición "CIUDAD CAPITAL".
- **Valores posibles:** ALTA VERAPAZ, BAJA VERAPAZ, CIUDAD CAPITAL, GUATEMALA, PETÉN, QUICHÉ, SACATEPÉQUEZ, SOLOLÁ, etc.
- **Tratamiento aplicado:** Se convirtieron los textos a mayúsculas, se limpiaron espacios y se corrigieron tildes faltantes usando un catálogo estándar de departamentos (Ej. PETEN -> PETÉN).
- **Variables derivadas:** Ninguna.

4. MUNICIPIO

- **Descripción:** Nombre del municipio donde se ubica el establecimiento. En el caso de "CIUDAD CAPITAL", reporta la zona.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Catálogo oficial del INE/Wikipedia por departamento, y de ZONA 1 a ZONA 25 para Ciudad Capital.
- **Valores posibles:** COBÁN, MIXCO, ZONA 10, etc.
- **Tratamiento aplicado:** Transformación a mayúsculas, normalización de espacios y corrección de tildes según diccionario municipal.
- **Variables derivadas:**
 - **MUNICIPIO_VALIDO:** (Booleano) True si el municipio hace match exacto con el diccionario oficial del INE/Wikipedia para su departamento correspondiente, False de lo contrario.

5. ESTABLECIMIENTO

- **Descripción:** Nombre oficial del centro educativo.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Nombres en mayúsculas, letras, números y signos de puntuación válidos.
- **Valores posibles:** Múltiples (ej. INSTITUTO MIXTO NOCTURNO FRANCISCO MARROQUIN).
- **Tratamiento aplicado:** Eliminación de caracteres invisibles, normalización de múltiples espacios internos y reemplazo de acentos graves por agudos. Se eliminaron comillas dobles si envolvían toda la cadena. Valores vacíos explícitos se pasaron a NA. Unificación por similitud estricta (tildes).
- **Variables derivadas:** Ninguna.

6. DIRECCION

- **Descripción:** Dirección física de las instalaciones del establecimiento.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Direcciones (alfanumérico). NA si es placeholder.
- **Valores posibles:** Múltiples (ej. "6A. AVENIDA 1-15 ZONA 4").
- **Tratamiento aplicado:** Eliminación de espacios invisibles/múltiples, eliminación de signos de puntuación irregulares en los bordes. Reemplazo de placeholders ("SIN DATO", "---", etc.) por NA.
- **Variables derivadas:** Ninguna.

7. TELEFONO

- **Descripción:** Números de teléfono de contacto del establecimiento.
- **Tipo de dato:** Texto (lista de números separados por punto y coma ;).
- **Dominio permitido:** Dígitos de 8 caracteres separados por ;. NA si es faltante/inválido.
- **Valores posibles:** Ej. 22202870, 22202870; 22202873.
- **Tratamiento aplicado:** Se estandarizaron separadores (comas, "Y", "/"). Se reconstruyeron números abreviados (ej. 22202870-73 a 22202870; 22202873). Se eliminaron etiquetas como "FAX" y "EXT". Los caracteres imposibles se documentaron en observación.
- **Variables derivadas:**
 - TELEFONO_ORIGINAL: (Texto) El valor crudo para trazabilidad y auditoría.
 - TELEFONO_CANTIDAD: (Numérico entero) Cantidad de números extraídos exitosamente.
 - TELEFONO_VALIDO: (Booleano) True si todos los números extraídos tienen longitud válida (8 dígitos).
 - TELEFONO_OBSERVACION: (Texto libre) Motivos de invalidez o notas de extracción (ej. "incluye FAX", "vacío", "longitud invalida").

8. SUPERVISOR

- **Descripción:** Nombre de la persona encargada de la supervisión escolar del MINEDUC asignada.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Cadenas de nombres propios, NA si falta.
- **Valores posibles:** Múltiples (ej. JORGE EDUARDO PAQUE LAZARO).
- **Tratamiento aplicado:** Eliminación de múltiples espacios y caracteres invisibles. Corrección de acentos graves. Reemplazo de placeholders ("---", "S/D") a NA. Unificación automática de nombres idénticos que solo diferían por tildes.

- **Variables derivadas:** Ninguna.

9. DIRECTOR

- **Descripción:** Nombre del director del centro educativo.
- **Tipo de dato:** Texto libre.
- **Dominio permitido:** Cadenas de nombres propios, NA si falta.
- **Valores posibles:** Múltiples nombres de personas.
- **Tratamiento aplicado:** Normalización completa (espacios, caracteres invisibles, corrección de acentos graves). Conversión de valores vacíos y placeholders genéricos ("---", "SIN DATO", ".") a valor nulo explícito NA. Unificación por presencia de tildes.
- **Variables derivadas:** Ninguna.

10. NIVEL

- **Descripción:** Nivel educativo de los datos extraídos (condición del proyecto).
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** "DIVERSIFICADO"
- **Valores posibles:** DIVERSIFICADO
- **Tratamiento aplicado:** Normalización de espacios y mayúsculas para estandarización.
- **Variables derivadas:** Ninguna.

11. SECTOR

- **Descripción:** Naturaleza jurídica / administración financiera del establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Lista controlada según sistema (ej. PRIVADO, OFICIAL, COOPERATIVA).
- **Valores posibles:** PRIVADO, OFICIAL, MUNICIPAL, COOPERATIVA.
- **Tratamiento aplicado:** Normalización de espacios y conversión a mayúsculas.
- **Variables derivadas:** Ninguna.

12. AREA

- **Descripción:** Tipo de área demográfica de asentamiento de la escuela.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** URBANA, RURAL (y SIN ESPECIFICAR por consistencia de origen).
- **Valores posibles:** URBANA, RURAL, SIN ESPECIFICAR.
- **Tratamiento aplicado:** Normalización de espacios y mayúsculas.

- **Variables derivadas:** Ninguna.

13. STATUS

- **Descripción:** Situación operativa actual del establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Estados operacionales del MINEDUC.
- **Valores posibles:** ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE.
- **Tratamiento aplicado:** Limpieza de espacios y estandarización a mayúsculas.
- **Variables derivadas:** Ninguna.

14. MODALIDAD

- **Descripción:** Idioma y enfoque educativo.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Modalidades lingüísticas reconocidas.
- **Valores posibles:** MONOLINGUE, BILINGUE.
- **Tratamiento aplicado:** Normalización de espacios, estandarización a mayúsculas.
- **Variables derivadas:** Ninguna.

15. JORNADA

- **Descripción:** Horario de funcionamiento de clases.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Jornadas del MINEDUC.
- **Valores posibles:** MATUTINA, VESPERTINA, NOCTURNA, DOBLE, INTERMEDIA.
- **Tratamiento aplicado:** Estandarización a mayúsculas, recortes de espacio.
- **Variables derivadas:** Ninguna.

16. PLAN

- **Descripción:** Plan o tipo de asistencia escolar.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Planes educativos del MINEDUC.
- **Valores posibles:** DIARIO(REGULAR), FIN DE SEMANA, SEMIPRESENCIAL, A DISTANCIA.
- **Tratamiento aplicado:** Remoción de espacios extra y conversión a formato uniforme.
- **Variables derivadas:** Ninguna.

17. DEPARTAMENTAL

- **Descripción:** Entidad Departamental del MINEDUC encargada de la administración sobre el establecimiento.
- **Tipo de dato:** Texto categórico.
- **Dominio permitido:** Departamentos, con subdivisiones de GUATEMALA y QUICHÉ (Norte, Sur, Oriente, Occidente).
- **Valores posibles:** ALTA VERAPAZ, GUATEMALA NORTE, QUICHÉ NORTE, etc.
- **Tratamiento aplicado:** Conversión a mayúsculas, adición de tildes oficiales en concordancia con DEPARTAMENTO (Ej. QUICHÉ). Validado respecto al departamento base para asegurar congruencia jerárquica territorial.
- **Variables derivadas:** Ninguna.

Informe de Calidad de Datos (Antes vs. Después)

A continuación, se presenta la validación del conjunto de datos limpio comparando el estado inicial contra el final tras aplicar el proceso de normalización:

Tabla 1. Informe de calidad de datos (antes vs. despues del proceso de limpieza)

Métrica	Antes	Después	Justificación de cambios
Registros	11,867	11,867	No se eliminaron registros, el sistema de MINEDUC asocia un registro distinto por combinación jornada/plan.
Variables (columnas)	17	24	Se agregaron 7 columnas derivadas para validación explícita (DISTRITO_FORMATO, DISTRITO_VALIDO, MUNICIPIO_VALIDO, TELEFONO_ORIGINAL, TELEFONO_CANTIDAD, TELEFONO_VALIDO, TELEFONO_OBSERVACION).
Valores faltantes	4,263	4,286	Subida esperada. Placeholders tipo "---", "SIN DATOS" o "S/D" fueron convertidos a nulos explícitos (NA) para mediciones reales.
% de faltantes	2.11%	2.12%	Aumento derivado de la conversión de texto genérico a NA.
Variables con NA	6	6	Las variables que contienen datos nulos se mantuvieron estables (Director, Supervisor, Dirección, etc).
Duplicados exactos (fila completa)	0	0	No existían filas 100% idénticas en todas sus columnas en el origen.

Métrica	Antes	Después	Justificación de cambios
Posibles duplicados parciales	3,726	2,075	Se redujeron las discrepancias parciales (similitud difusa) gracias a la corrección estandarizada de tildes en nombres propios. De los 2,075 restantes, 463 se clasifican como probables duplicados (misma dirección y/o teléfono) y 1,520 como probablemente distintos (dirección diferente); ver Reportes/ResumenDecisionesDuplicados.csv.
Establecimientos únicos	6,313	5,833	Al corregir variaciones ortográficas (ej. GONZÁLEZ vs GONZALEZ), entidades lógicamente idénticas se unificaron, reduciendo el total.
Variables con formato inconsistente	8	0	8 variables necesitaban corrección de formato (espacios, tildes, comillas, separadores de teléfono, placeholders); tras la limpieza ninguna las conserva.
Variables con tipo incorrecto	0	0	Ninguna variable era un número almacenado como texto: los identificadores (CODIGO, DISTRITO, TELEFONO) se conservan como texto a propósito. La única numérica es la derivada TELEFONO_CANTIDAD, creada con el tipo correcto.
Categorías inconsistentes (variantes de escritura)	142	0	142 grafías distintas representaban el mismo valor (ej. PETEN/PETÉN, tildes en municipios); se homologaron a su forma canónica.
Errores corregidos (registros modificados)	11,127	0	Total de registros modificados sumando todas las transformaciones (ver Reportes/RegistroTransformaciones.csv, columna <i>Registros afectados</i>).

Reproducibilidad y trazabilidad. Todas las transformaciones aplicadas fueron guardadas para reproducibilidad en Reportes/RegistroTransformaciones.csv. Los 2,075 posibles duplicados parciales se conservaron sin eliminar (según las instrucciones del proyecto que prohíben su eliminación automática) y cada par recibió una decisión documentada por regla en Reportes/PosiblesDuplicadosParciales.csv, resumida en Reportes/ResumenDecisionesDuplicados.csv.